



המכללה האקדמית להנדסה סמי שמעון

מדור בחינות ומערכת שעות

הנדסת תוכנה

14/01/19  
09:00-12:00

## מבוא לאחזור מידע

מועד א'  
ליטבק מרינה

תשע"ט סמסטר א'

חומר עזר – אסור (מלבד דפי הנוסחאות המצורפים לטופס זה)

השאלון מכיל 13 עמודים (כולל נספח וטייטה).

=====

### חומר עזר : נא סמן במשבצת המתאימה את המתאים

\* ☐ ניתן להשתמש בכל מחשבון  
\* ☐ לא ניתן להשתמש במחשבון Casio FX-991EX  
\* ☐ לא ניתן להשתמש במחשבון

\* ☐ לא ניתן להשתמש בחומר עזר  
\* ☐ מותר שימוש בדף נוסחאות, כמפורט: \_\_\_\_\_  
\* ☐ הבחינה בחומר פתוח – מותר להשתמש בכל חומר עזר מודפס או כתוב

### הערות

\* ☐ יש לענות על כל השאלות במקומות המיועדים ע"ג טופס השאלון בלבד  
יש להחזיר את השאלון ביחד עם הכריכה/מחברת.

אחר:

\_\_\_\_\_.1  
\_\_\_\_\_.2  
\_\_\_\_\_.3

השאלון מכיל 9 עמודים (כולל עמוד זה).

בהצלחה !

=====



שאלה 1 (25 נק')

- יש לענות לכל השאלות
- יש לסמן באופן ברור את התשובה הנכונה ביותר על גבי שאלון הבחינה
- סימון של יותר מתשובה אחת לאותה שאלה יקבל ציון של אפס

א. (5 נק') ערך אפשרי של Jaccard similarity נכלל בתחום הבא:

1.  $[0, 1]$
2.  $[0, \infty]$
3.  $[-\infty, 1]$
4.  $[-\infty, \infty]$

תשובה (1/ 2/ 3/ 4) נימק:

ב. (5 נק') תפקיד של clustering הוא:

1. לחשב שכיחות של המילים במסמך
2. לצמצם כל מילה לשורש-מילה
3. לזהות קבוצות של מסמכים דומים
4. להוציא מילות מפתח עבור מסמך

תשובה (1/ 2/ 3/ 4) נימק:

ג. (5 נק') אלגוריתם למידה בשם NaiveBayes מקבל כקלט מסמכים בצורה של:

1. ווקטור (Vector Space Model)
2. BOW (Bag of words)
3. גרף
4. טקסט ללא מילות עצירה

תשובה (1/ 2/ 3/ 4) נימק:

ד. (5 נק') מילות עצירה (stop words) אלא מילים שניתן לאפיין על-ידי:

1. tf (term frequency) גבוה ו- idf (inverse document frequency) נמוך
2. tf (term frequency) גבוה ו- idf (inverse document frequency) גבוה
3. tf (term frequency) נמוך ו- idf (inverse document frequency) נמוך
4. tf (term frequency) נמוך ו- idf (inverse document frequency) גבוה

תשובה (1/ 2/ 3/ 4) נימק:

ה. (5 נק') נתון ביטוי "Natural Language Processing". ניתן לאחזר מסמכים שמכילים אותו בעזרת:

1. אינדקס אפוך (inverted index) בנוי על מילים בודדות ושאלטה "Natural AND Language AND Processing"
2. אינדקס אפוך בנוי על זוגות המילים (bi-grams) ושאלטה "Natural Language AND Language Processing"
3. אינדקס אפוך בנוי על מילים בודדות עם מיקומם בתוך מסמך ושאלטה "Natural AND Language AND Processing"
4. מדידת דמיון כ- cosine similarity בין ווקטורים של מסמכים ושאלטה

תשובה (1/ 2/ 3/ 4) נימק:



שאלה 2 (25 נק')

נתונים ששה מסמכים (a-h הם המילים):

a h a b a h c b :D1

h b e b h :D2

d h b h d :D3

h d d a h a e :D4

d h d :D5

h c a h c a :D6

מסווגים לשלוש קטגוריות: P, B and S באופן הבא:

מסמך	קטגוריה
D1	P
D2	N
D3	N
D4	P
D5	N
D6	P

א. (10 נק') לא נתונה רשימת מילות עצירה (stop words), אך ישנה דרישה לסנן אותם מהמסמכים. כיצד ניתן לעשות זאת? תציע שיטה ותראה את היישום שלה על המאגר הנתון. יש להראות את התוכן המסמכים לאחר סינון.

---



---



---



---

\_\_\_\_\_ :D1  
 \_\_\_\_\_ :D2  
 \_\_\_\_\_ :D3  
 \_\_\_\_\_ :D4  
 \_\_\_\_\_ :D5  
 \_\_\_\_\_ :D6

ב. (15 נק') יש לבצע בחירת מאפיינים (feature selection) בעזרת שיטה  $\chi^2$

---



---



---



---



---



---



---



---



---



---



---



---



---



---



---



---



נתונים ששה מסמכים

[illegible]

\_\_\_\_\_

\_\_\_\_\_

\_\_\_\_\_

\_\_\_\_\_

\_\_\_\_\_

a c d a e :D9 .iii

[illegible]

\_\_\_\_\_

\_\_\_\_\_

\_\_\_\_\_





**שאלה 4 (20 נק')**

ניתן מאגר של ששה מסמכים המתוארים בשאלה מסי 2 ושאלתה Q: a h d h a.  
יש לדרג שלושה מסמכים הראשונים (D1, D2, D3) ביחס לשאלתה תוך שימוש ב- tf-idf ו-  
cosine similarity. יש להתחשב בכל המאגר לחישוב idf.

This image shows a single sheet of white paper with horizontal ruling lines. The lines are evenly spaced and run across the width of the page. There are no margins, text, or other markings on the paper.



**NaiveBayes Classifier:**

$$l = \arg \max_c \hat{P}(c) \prod_i \hat{P}(x_i | c)$$

$$\hat{P}(c_j) = \frac{N(C = c_j)}{N} \quad \hat{P}(x_i | c_j) = \frac{N(X_i = x_i, C = c_j) + 1}{N(C = c_j) + k}$$

**Multinomial NB = One feature  $X_i$  for each word position in document**

$$\text{Jaccard}(A, B) = |A \cap B| / |A \cup B|$$

$$\text{Cosine similarity:} \quad \cos(\vec{q}, \vec{d}) = \frac{\vec{q} \cdot \vec{d}}{|\vec{q}| |\vec{d}|} = \frac{\vec{q}}{|\vec{q}|} \cdot \frac{\vec{d}}{|\vec{d}|} = \frac{\sum_{i=1}^{|\mathcal{V}|} q_i d_i}{\sqrt{\sum_{i=1}^{|\mathcal{V}|} q_i^2} \sqrt{\sum_{i=1}^{|\mathcal{V}|} d_i^2}}$$

**Term frequency:**

$$\text{tf}(t, d) = \frac{f(t, d)}{\max\{f(w, d) : w \in d\}}$$

**Inverse document frequency (idf):**

$$\text{idf}(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

**Chi-square ( $\chi^2$ ):**

$$\chi^2(\mathbb{D}, t, c) = \sum_{e_t \in \{0,1\}} \sum_{e_c \in \{0,1\}} \frac{(N_{e_t e_c} - E_{e_t e_c})^2}{E_{e_t e_c}}$$



טירטור:











